PROJETO BENCHMARK CIIA-DF / SEI

O Papel e o Objetivo dos Agentes de IA no Benchmark

Autor: Gustavo Antônio (Arquitetura Hermes & Avaliação) | **Contexto:** Projeto de Orquestração SEI (CIIA / NIAUnDF)

Resumo Executivo: *Este relatório consolida a finalidade operacional, científica e institucional dos agentes autônomos no projeto. Para além da comparação técnica entre frameworks (Hermes vs. LangGraph), os agentes atuam como* ***analistas públicos digitais*** *voltados para triagem, instrução e conformidade processual no Sistema Eletrônico de Informações (SEI).*

1. O Objetivo Prático: Para Além do Benchmark

Em sua dimensão aplicada, o projeto responde ao represamento de processos administrativos e à sobrecarga dos servidores em conferências manuais repetitivas. O agente de IA não é concebido como um chatbot consultivo, mas como um **assistente autônomo com capacidade de instrução e ação executiva** no SEI.

- **Instrução e Triagem Processual:** Recebe a tarefa (ex: auditar prestação de contas, checar regularidade para pagamento de fatura ou renovação contratual) e navega pelo processo extraindo metadados, partes interessadas e a cronologia dos autos.
- **Confronto Normativo e Checklist Regulatório:** Consulta a base de regras institucionais e verifica a presença obrigatória de peças (certidões negativas válidas, atesto de fiscal, nota de empenho e parecer prévio).
- **Tomada de Decisão com Ações Concretas de Escrita:** Detectando inconformidade, aciona registrar_pendencia indicando com precisão o dispositivo legal pendente. Estando regular, aciona salvar_minuta para minutar despacho ou parecer técnico para chancela do servidor.

2. As Ferramentas Padronizadas (Tool Catalog)

Para garantir isolamento de segurança e evitar acessos diretos ao banco de dados relacional, ambos os agentes operam estritamente por meio de uma API REST comum exposta pelo Backend (FastAPI):

Ferramenta	Tipo	Finalidade Operacional no Domínio do SEI
consultar_processo	Leitura	Recupera metadados do processo, interessados, tramitação e lista de documentos anexados.
buscar_documentos	Leitura (RAG)	Busca semântica/léxica no acervo de PDFs processados, retornando trechos com página e ID de origem.
ler_documento	Leitura	Lê a íntegra ou páginas específicas de uma peça processual para extração detalhada de dados e valores.
consultar_requisitos	Leitura	Consulta checklists de conformidade e critérios normativos do tipo de processo informado.
registrar_pendencia	Escrita (Idempotente)	Formaliza e registra inconformidade ou falta de documento com chave única de idempotência.
salvar_minuta	Escrita (Idempotente)	Grava minuta fundamentada de parecer ou despacho para homologação final do servidor humano.

3. O Papel do Hermes no Benchmark Científico

No desenho comparativo, o **Hermes** atua como o representante do **paradigma autônomo ReAct / Tool-Calling nativo**, contrastado diretamente com o **LangGraph** (paradigma orquestrado por grafo de estados):

Dimensão	Hermes (Agente Autônomo)	LangGraph (Orquestrador por Grafo)
Filosofia de Controle	Loop dinâmico orientado a tool-calling. A LLM decide a cada turno a próxima ação e o término.	Grafo determinístico com nós explícitos e arestas condicionais predefinidas em código.
Flexibilidade	Alta adaptabilidade a caminhos imprevistos e investigações exploratórias livres.	Fluxos estruturados e previsíveis, com transições de estado estritas.
Overhead & Custo	Avalia se a autonomia gera chamadas redundantes ou loops excessivos de raciocínio.	Avalia o overhead computacional de serialização de estado e tempo por transição de nó.
Resiliência	Tolerância a buscas vazias (retornos sem peças) e autocorreção na iteração seguinte.	Tratamento de exceções com rollback condicional de nó e limites rígidos de recursão.

4. A Nova Proposta Metodológica: Benchmark em Duas Camadas

A proposta recente introduz uma separação estrita para responder aos requisitos de **soberania de dados e LGPD no Governo do Distrito Federal (GDF)**:

- **Camada 1 (Benchmark de Orquestradores):** Fixa o modelo de inferência (ex: Llama 3.1 70B ou GPT-4o) e isola o comportamento algorítmico do Hermes vs. LangGraph, medindo overhead de tokens internos e velocidade de ciclo.
- **Camada 2 (Benchmark de Modelos de Linguagem):** Fixa o orquestrador padronizado e compara modelos *Open-Weights* locais (Qwen 2.5 72B / Llama 3.1 70B via vLLM) contra modelos de ponta em nuvem (Claude 3.5 Sonnet / GPT-4o), avaliando se instâncias locais atingem paridade sem enviar autos para nuvens externas.
- **Estratégia de Cache Articulada:** Isola *Cold-Start Runs* (sem cache, teste puro de busca) de *Warm-Start Runs* (com Prefix Caching e Tool-Call Caching), mensurando a redução de até 90% em custos de tokens em processos volumosos.

5. Requisitos Inegociáveis e Governança Pública

Para a administração pública, a conformidade normativa precede a velocidade. O benchmark adota filtros binários eliminatórios:

1. **Fidelidade Factual Absoluta (0 ou 1):** A resposta do agente não pode conter alucinações ou fatos ausentes dos autos.
2. **Citação Precisa de Fonte (0 ou 1):** Toda conclusão ou apontamento de pendência deve referenciar expressamente o número do documento e o número exato da página no PDF.
3. **Rastreabilidade Completa (ExperimentRun):** Toda execução gera um identificador único auditável com tokens, tempos e histórico de ferramentas acionadas.

Conclusão: O benchmark une rigor metodológico acadêmico à entrega prática de uma solução governamental auditável, eficiente e aderente à LGPD para a gestão de processos no Distrito Federal.