

Orçamento Computacional Detalhado: Projeto Hermes (Hermes e LangGraph)

CIIA • UnDF

Orçamento proposto por Gustavo Antonio

De 21 de setembro a 10 de dezembro de 2026

1. Cronograma de Implantação e Demanda de Recursos

De acordo com o planejamento, o consumo da infraestrutura variará conforme os marcos do projeto:

- **Setembro (21 a 27):** Configuração inicial do ambiente e das equipes. Demanda leve de processamento para subida dos primeiros containers.
- **Outubro (até 30/10):** Desenvolvimento da base de dados, casos de desenvolvimento e fim de funcionalidades em 30 de outubro. Haverá picos de uso de CPU durante a extração e divisão de texto dos PDFs do processo no ambiente.
- **Novembro (até 06/11 e 27/11):** Congelamento de versões em 6 de novembro e rodadas do experimento principal (com 360 execuções simuladas e validações) entre 9 e 15 de novembro. Fase de uso extremo de RAM no banco de dados e tráfego máximo nas chamadas HTTP para o provedor de IA. Entrega final do artigo em 27/11.

2. Como o Hardware Apoia Cada Frente de Trabalho

Frente	Entrega sob sua responsabilidade	Benefício e Impacto do Hardware Alocado
Documentos (3)	Base, extração, chunks, busca e conferência das fontes.	O armazenamento SSD NVMe de alta taxa de transferência (I/O) garante a rápida ingestão dos PDFs. Múltiplos núcleos de processador (vCPU) sustentam o paralelismo da extração se o uso de OCR for acionado para páginas digitalizadas.
Backend (3)	Banco, API, validação e ferramentas compartilhadas.	A alocação generosa de memória RAM sustenta o banco PostgreSQL e conexões concorrentes da API sem travamentos. Evita gargalos ao validar esquemas de entrada e saída em milissegundos durante o experimento.
Hermes (2)	Configuração, integração de ferramentas e logs do executor.	A rede simétrica de alta velocidade (1 Gbps) garante estabilidade no timeout explícito do HTTPX, permitindo que a integração envie comandos ao modelo e colete eventos rapidamente sem derrubar a conexão.

Frente	Entrega sob sua responsabilidade	Benefício e Impacto do Hardware Alocado
LangGraph (2)	Grafo, estado, ferramentas e limites do executor.	O ambiente virtual isolado nos containers do servidor mantém o estado e as mensagens persistentes na memória volátil, suportando os limites de recursão aplicados às rodadas intensivas de benchmark.
Infraestrutura (2)	VPS, containers, persistência e execução reproduzível.	Como gestora técnica do ambiente, depende dos recursos físicos exatos (Linux nativo, disco robusto para backups e volumes) para que a replicação do Compose seja exata a cada rodada.
Metodologia (2)	Tarefas, rubricas, avaliação e análise experimental.	Utilizará a capacidade de processamento do servidor e do PostgreSQL para gerar análises e extrações em lote (usando bibliotecas como SciPy e Pandas) a fim de calcular variância, custos e latência finais.
Coordenação (1)	Arquitetura, prioridades, integração e edição do artigo.	O tempo de atividade do servidor (uptime) viabiliza a transparência das demonstrações para revisão coletiva, onde o protótipo funcional deve rodar sempre que exigido.

3. Demanda Computacional da Stack Tecnológica

A stack proposta impõe requisições específicas de ambiente e processamento:

Componente	Stack proposta	Exigência Exata de Recursos Computacionais
Linguagem / API	Python 3.11 ou 3.12, FastAPI, Pydantic	~1 a 2 GB RAM e 1 vCPU; requer baixo custo computacional apenas para instanciar os workers da API REST.
Banco de Dados	PostgreSQL, SQLAlchemy e pgvector	Altamente intensivo em RAM. Mínimo de 4 GB a 8 GB de RAM alocados caso a busca vetorial (embeddings) e busca textual rodem concorrentemente sob estresse no experimento principal.
Extração Documental	PyMuPDF e Tesseract (OCR em português)	Altamente intensivo em CPU. Pede de 2 a 4 vCPUs modernos (ex: linha AMD EPYC) para evitar afogamento da máquina se o Tesseract processar várias imagens de documentos e despachos escaneados de uma só vez.
Agentes e Rede	Hermes, LangGraph e HTTPX	Baixo impacto de CPU, mas total dependência de conectividade (Bandwidth e Velocidade). Requer banda mínima de 1 Gbps para despachar requisições

Componente	Stack proposta	Exigência Exata de Recursos Computacionais
		para a API do modelo de linguagem sem latência falsa.
Ambiente de Testes	Linux e Docker Compose (pytest, pandas, SciPy, Matplotlib)	Subir o banco, API, workers e executar scripts analíticos simultaneamente consumirá até 4 GB em repouso absoluto. Recomendação de sistema total: 16 GB de RAM para margem segura e evitar falhas (OOM - Out of Memory).

4. Comparativo de Servidores e Fontes de Hardware (Valores Atualizados)

Levando em consideração a demanda intensiva de I/O de disco para OCR e RAM para a base de dados vetorial, analisamos duas opções de hospedagem. Após revisão da tabela de preços atualizada, os valores refletem o custo operacional real de uma contratação avulsa mensal para o trimestre do projeto.

4.1. Hostinger (Plano KVM 4)

- **Particularidades:** Focada em facilidade de uso, oferece um painel web próprio muito amigável. Apesar de parte do custo ir para essa camada de gerenciamento visual, o plano KVM 4 se provou extremamente competitivo no mercado atual para instâncias de 16 GB de RAM frente aos reajustes de outras provedoras.
- **Capacidade Típica:** 4 núcleos vCPU (AMD EPYC), 16 GB de RAM, 200 GB de Disco NVMe de alta velocidade e rede de 1 Gbps.
- **Preço Regular (Mensal / Sem Fidelidade):** R\$ 129,99 no primeiro mês e R\$ 196,99/mês nas renovações subsequentes.
www.hostinger.com/br/servidor-vps?utm_source=google&utm_medium=cpc&utm_id=24253699352&utm_campaign=Generic-VPSINT.SaILO.BR&utm_term=

=kvm+4&utm_content=824683434165&qad_source=1&qad_campaignid=24253699352&qclid=CjwKCAjwwrPVEhA1EiwAv_YO-YiIS4Qul3T3QqXAOKR7EoZuj16Bwp1Oa1MapcdSiY5Tb1KCUa9KpRoCeRgQAvD_BwE

- **Fontes Consultadas:** Tabela de preços VPS da Hostinger (Plano KVM 4 Mensal).

4.2. Hetzner Cloud (Instância CPX42 - Arquitetura AMD64)

- **Particularidades:** Provedor com foco puramente técnico, entregando altíssimo poder computacional bruto (8 núcleos). Contudo, a tabela de preços atualizada posiciona esta instância de alto desempenho em uma categoria premium, inviabilizando-a como opção de "baixo custo" para este escopo específico.
- **Capacidade Típica:** 8 núcleos vCPU (AMD), 16 GB de RAM, 320 GB de Disco NVMe.
- **Preço Regular (Mensal Fixo):** € 69,99 mensais (Cerca de R\$ 425,00 por mês, valor linear da tabela no site oficial).
<https://www.hetzner.com/cloud/regular-performance/>
- **Fontes Consultadas:** Catálogo Cloud da Hetzner (Instâncias CPX).

4.3. Inteligência Artificial (OpenRouter - Múltiplos Modelos)

- **Capacidade:** API unificada (compatível com o padrão OpenAI) que permite alternar entre dezenas de modelos (ex: GPT-4o-mini, Claude 3.5 Haiku, Llama 3.1 70B) trocando apenas a string do modelo. É essencial selecionar modelos com suporte nativo a Function Calling / Tools para validar os esquemas Pydantic.
- **Preços de Referência:** Modelos de categoria eficiente variam entre \$0,10 e \$1,00 USD por 1 milhão de tokens. <https://openrouter.ai/>

5. Orçamento Total Precificado

Com a constatação de que a instância CPX42 da Hetzner eleva o custo trimestral do servidor para mais de R\$ 1.200,00, a alocação oficial retorna para a **Hostinger (KVM 4)** combinada ao provedor **OpenRouter**, mantendo o projeto dentro da viabilidade financeira estrita:

Item / Serviço	Descrição e Escopo	Custo Estimado

Hospedagem VPS Hostinger KVM 4	3 Meses de uso (1º mês a R\$ 129,99 + 2 meses de R\$ 196,99)	R\$ 524,00
Consumo LLM via OpenRouter	Piloto + Experimento Multi-Modelo (1.080 execuções, ~150M Tokens, ~\$30 a \$40 USD)	De R\$ 170,00 a R\$ 220,00
Total Geral (Trimestre)	Custo Operacional Tecnológico Final	De R\$ 694,00 a R\$ 744,00

Este documento crava que a junção da VPS Hostinger (com 16GB de RAM suficientes para o banco vetorial) com o agregador OpenRouter é a decisão mais segura para manter o orçamento contido, absorvendo o experimento massivo de múltiplos modelos sem estourar a verba de infraestrutura.